

Inferencia Aproximada

- Modelos con múltiples capas generan posteriores intratables.
- El concepto de inferencia exacta se puede describir como un problema de optimización.
- Se pretende estimar $\log(p(v; \theta))$
 - v: datos observados
 - h: variables latentes
 - θ : parámetros
- Se busca calcular una cota (Lower Bound) $L(v, \theta, q)$ de $\log(p(v; \theta))$; denominada Evidencia Lower Bound (ELBO)
- ELBO también se conoce como la negative variational free energy.

$$L(v, \theta, q) = \log p(v; \theta) - D_{KL}(q(h|v) || p(h|v; \theta))$$

Suponga que se quiere marginalizar:

$$p(x) = \int_z p(x, z) dz$$

$$\log p(x) = \log \int_z p(x, z) dz$$

Si se arregla $q(z)$:

$$\log p(x) = \log \int_z p(x, z) \frac{q(z)}{q(z)} dz = \log \mathbb{E}_q \left\{ \frac{p(x, z)}{q(z)} \right\}$$

Por la desigualdad de Jensen:

$$\log \mathbb{E}_q \left\{ \frac{p(x, z)}{q(z)} \right\} \geq \mathbb{E}_q \left\{ \log \frac{p(x, z)}{q(z)} \right\}$$

$$\log p(x) = \log \mathbb{E}_q \left\{ \frac{p(x, z)}{q(z)} \right\} \geq \mathbb{E}_q \left\{ \log \frac{p(x, z)}{q(z)} \right\}$$

$$\log p(x) \geq \mathbb{E}_q \left\{ \log \frac{p(x, z)}{q(z)} \right\} = L$$

L es cota sobre la evidencia $p(x)$.

Si se analiza desde el posterior. $P(z|x)$ aprox. por $q(z)$.

$$D_{KL}(q(z) || p(z|x)) = -\mathbb{E}_q \left\{ \log \frac{P(z|x)}{q(z)} \right\}$$

$$= -\mathbb{E}_q \left\{ \log P(z|x) - \log q(z) \right\}$$

$$P(z|x) = \frac{P(x,z)}{P(x)}$$

$$\begin{aligned} D_{KL}(q(z) || P(z|x)) &= -\mathbb{E}_q \left\{ \log \frac{P(z|x)}{P(x)} - \log q(z) \right\} \\ &= -\mathbb{E}_q \left\{ \log P(z|x) - \log q(z) - \log P(x) \right\} \\ &= -\mathbb{E}_q \left\{ \log \left(\frac{P(z|x)}{q(z)} \right) \right\} + \mathbb{E}_q \left\{ \log P(x) \right\} \\ &\quad - L \end{aligned}$$

$$D_{KL}(q(z) || P(z|x)) = -L + \log P(x)$$

$$L = \log P(x) - D_{KL}(q(z) || P(z|x))$$

→ Para $q(z)$ apropiado, L es tratable.

→ Se busca $q(z)$ que maximiza L .

→ Incluso, en forma canónica, respecto a las variables h, v y θ :

$$L(v, \theta, q) = \mathbb{E}_{h \sim q} \left\{ \log p(h, v) \right\} + H(q)$$

$$q(z) = q(h|v)$$

L es tratable.

Expectation maximization

→ Algoritmo clásico basado en ELBO

E-step: $\theta^{(0)}$: ptos. iniciales.

$$q(h^{(i)} | v) = p(h^{(i)} | v^{(i)}, \theta^{(0)})$$

M-step:

$$\max_{\theta} \sum_i L(v^{(i)}, \theta, q)$$

Para DL M-step es difícil.

Maximum a Posteriori - MAP.

- Generalmente estamos interesados en calcular las variables latentes $p(h|v)$.
- Como alternativa al cálculo de la distribución, se busca calcular los valores más probables:
$$h^* = \arg \max_h p(h|v)$$
- MAP indirectamente provee un valor de q en inferencia aproximada desde 1.

Variational Inference

- El proceso de inferencia busca q maximizando \mathcal{J} .
- El proceso de aprendizaje (learning), busca θ maximizando \mathcal{J}
- **Variational Learning:** max. \mathcal{J} sobre una familia restringida de distribuciones q.
- Se busca facilitar el cálculo de $\mathbb{E}_q \{ \log p(h, v) \}$
- En general, se restringe la factorización de q:
$$q(h|v) = \prod_i q(h_i|v)$$

(mean Field).

- Se impone un modelo gráfico estructurado sobre q para fijar las interacciones que se quieren capturar con la aprox.
- Para variables discretas se optimiza un # finito de variables discretas
- Para variables continuas se debe considerar calculus of variations.

↳ Resolver para una función $f(x)$ no para θ en \mathbb{R}^P